INFORME TÉCNICO: PROCESOS ETL Y JUSTIFICACIÓN METODOLÓGICA

Módulo 5 (Cartera de Inversión Pública – Datos Abiertos MEF)

Departamento de Análisis: Piura — Periodo: 2016–2021

16 de octubre de 2026

1 Cartera de Inversión Pública (Datos Abiertos)

1.1 Selección de la fuente

El portal de Datos Abiertos del MEF publica nueve conjuntos de datos en la categoría *Inversión Pública*. Se eligió **Detalle de inversiones** porque es el único que contiene, a nivel de proyecto, todos los campos exigidos. Los demás se descartaron: *Estado situacional* está por producto y empieza en 2017; *Formato 12B* solo tiene la programación financiera por periodo; *Cierre de inversiones* e *Inversiones desactivadas* son subconjuntos; *Componentes*, *Expedientes técnicos*, *Indicadores de brechas* y *Directorio de operadores* no describen la cartera de proyectos.

Las variables se identificaron con el **diccionario oficial** (`Detalle_Inversiones_Diccionario.csv`, 68 variables) publicado junto al recurso:

Campo solicitado	Columna del MEF	Columna final
Código Único de Inversión	`CODIGO_UNICO`	`cui`
Ejecutora	`NOMBRE_UEI`	`ejecutora`
Nivel de gobierno	`NIVEL` (GN, GR, GL)	`nivel_gobierno`
Sector	`SECTOR`	`sector`
Función	`FUNCION`	`funcion`
Costo del proyecto	`COSTO_ACTUALIZADO`	`costo`
Grado de avance	`AVANCE_FISICO` / `AVANCE_EJECUCION`	`avance`
Fecha de inicio	`FEC_INI_EJECUCION`	`fecha_inicio`
Fecha de fin	`FEC_FIN_EJECUCION`	`fecha_fin`
Fecha de última ejecución	`ULTIMO_DEVENGADO`	`fecha_ult_ejec`

1.2 Estrategia y Justificación del Proceso de Extracción (Extract)

Se usó la **descarga directa del CSV** desde el servidor de archivos del portal (método 1 del cuaderno de la semana 5):

- URL: `https://fs.datosabiertos.mef.gob.pe/datastorefiles/DETALLE_INVERSIONES.csv` (archivo nacional de 247 MB, actualizado el 13/10/2026).

- Departamento: `DEPARTAMENTO = "PIURA"`; verificación cruzada con `UBIGEO`, cuyos dos primeros dígitos deben ser `"20"`.
- Variables extraídas: los diez campos solicitados más `NOMBRE_INVERSION`, `ESTADO`, `SITUACION`, `UBIGEO` y las columnas de respaldo para montos (`MONTO_VIABLE`, `DEVEN_ACUMUL_ANIO_ANT`, `DEV_ANIO_ACTUAL`) y fechas (`FEC_INI_EJEC_FISICA`, `FEC_FIN_EJEC_FISICA`, `PRIMER_DEVENGADO`, `ULT_FEC_DECLA_ESTIM`).

Por qué la descarga directa y no la API ni el scraping. El portal ofrece la API `datastore_search` (`resource_id = f9cc4ba0-931a-4b70-86c9-eacbd8c68596`), pero para este recurso devuelve `"records": null`, con o sin filtro por departamento. El scraping estático con BeautifulSoup tampoco es viable: la página del dataset se genera con JavaScript y `requests` no recibe los enlaces. La descarga directa es reproducible, no depende de la estructura HTML y trae la versión más reciente cada vez que se ejecuta.

Procedimiento.

1. **Descarga en memoria.** El CSV se lee desde un buffer (`BytesIO`), sin escribirlo en disco. Hasta tres intentos con 10 segundos de espera ante errores temporales (500, 503, conexión cortada); ante un 404 se detiene con un mensaje explícito, porque reintentar no lo resuelve.
2. **Codificación.** Se detecta en los primeros 2 MB (UTF-8 con respaldo *latin-1*); si el error de decodificación cae al final de la muestra, es solo un carácter acentuado cortado y el archivo se trata como UTF-8.
3. **Control de columnas.** Antes de leer se verifica que las columnas esperadas existan en la cabecera; si el MEF cambia un nombre, se emite una advertencia.
4. **Lectura por bloques.** Se lee en bloques de 50 000 filas, solo con las columnas necesarias (`usecols`) y como texto (`dtype=str`); en cada bloque se conservan únicamente las filas de Piura. El departamento se compara tras estandarizar el texto (mayúsculas, sin tildes ni espacios extra).
5. **Validación.** Si no se encuentra ninguna inversión de Piura, el proceso se detiene con error en lugar de continuar con una base vacía.

1.3 Decisiones de Transformación (Transform)

Estandarización. Los nombres de columna se pasan a minúsculas. El CUI se convierte a entero (`Int64`); se eliminan registros sin CUI y CUI duplicados (se conserva el último). Las variables categóricas se normalizan (mayúsculas, sin tildes) para que, por ejemplo, "ADMINISTRACIÓN" y "ADMINISTRACION" cuenten como la misma categoría. Los montos se convierten a `float` retirando símbolos y separadores de miles.

Fechas a `datetime`. El archivo mezcla formatos, que se resuelven por patrón y no por posición:

Formato en la fuente	Ejemplo y columnas
`aaaa-mm-dd hh:mm:ss`	`2018-05-01 00:00:00` (`FEC_INI_EJECUCION`, `FEC_FIN_EJECUCION`)
`AAAAMM` (periodo SIAF)	`201806` (`PRIMER_DEVENGADO`, `ULTIMO_DEVENGADO`); se fija al día 1 del mes
`AAAAMMDD`, `dd/mm/aaaa`	Formatos de respaldo, por si cambian en futuras versiones

Las fechas fuera del rango 1990–2040 se consideran errores de registro y pasan a `NaT`. Cada fecha usa una columna principal y, si está vacía, una de respaldo:

- `fecha_inicio`: `FEC_INI_EJECUCION` → `FEC_INI_EJEC_FISICA` → `PRIMER_DEVENGADO`
- `fecha_fin`: `FEC_FIN_EJECUCION` → `FEC_FIN_EJEC_FISICA`
- `fecha_ult_ejec`: `ULTIMO_DEVENGADO` → `ULT_FEC_DECLA_ESTIM`

Grado de avance. Ambos avances se llevan a escala 0–100. Para el proyecto h se prioriza el avance físico; si falta, el financiero, y si este también falta, se calcula con el devengado acumulado:

$$\text{avance}_h = \begin{cases} \texttt{AVANCE_FISICO}_h & \text{si existe} \\ \texttt{AVANCE_EJECUCION}_h & \text{si no} \\ 100 \cdot \dfrac{\text{devengado_acum}_h}{\text{costo}_h} & \text{si ninguno existe} \end{cases}$$

La columna `fuente_avance` registra qué criterio se usó en cada proyecto (`fisico`, `financiero`, `imputado_cerrada`, `imputado_sin_ejecucion`), con $\text{devengado_acum}_h = \texttt{DEVEN_ACUMUL_ANIO_ANT}_h + \texttt{DEV_ANIO_ACTUAL}_h$.

Valores perdidos (NaN) y atípicos.

Condición	Tratamiento
Costo nulo o ≤ 0	Se usa `MONTO_VIABLE`; si tampoco es positivo, queda NaN y se excluye del ponderado
Avance físico nulo (1 190 casos)	Se usa el avance financiero
Avance aún nulo, inversión cerrada	100 % (se completó la ejecución)
Avance aún nulo, sin devengado ni ejecución	0 % (no inició la ejecución)
Fecha de fin nula (324 casos)	Se usa la fecha de última ejecución; si tampoco existe y no está cerrada, se considera abierta hasta la fecha de corte
Fecha de inicio nula	Se usa el inicio físico (F12-B) o el primer devengado; si aún falta, la fecha de última ejecución
Ejecutora nula (21 casos)	Se conserva sin imputar; no afecta a los agregados
Avance $>$ 100 % (22 casos)	Se recorta a 100 y se marca en `avance_excede_100` (sobrecostos)
Fecha fuera de 1990–2040	`NaT`

Cartera 2016–2021 y proyecto activo. Cada inversión tiene un periodo de ejecución efectivo:

$$\text{inicio}_h = \text{fecha_inicio}_h, \qquad \text{fin}_h = \max(\text{fecha_fin}_h,\ \text{fecha_ult_ejec}_h).$$

Un proyecto está **activo en el año** t si su periodo se superpone con ese año: $\text{inicio}_h \leq 31/12/t$ y $\text{fin}_h \geq 01/01/t$. La cartera detallada conserva las inversiones activas en al menos un año entre 2016 y 2021.

Agregado anual departamental. Con A_t el conjunto de proyectos activos en el año t, c_h el costo y a_h el avance:

$$N_t = |A_t|, \qquad \text{Costo}_t = \frac{1}{10^6}\sum_{h\in A_t} c_h, \qquad \text{Avance ponderado}_t = \frac{\sum_{h\in A_t} c_h\, a_h}{\sum_{h\in A_t} c_h}$$

El costo total se expresa en millones de soles. En el avance ponderado, un proyecto grande pesa más que uno pequeño, de modo que refleja la proporción del monto de la cartera que se ha ejecutado. Se verifica que el resultado esté entre 0 y 100.

Formato long y ancho. El agregado se construye en formato **ancho** (una fila por departamento-año), que es la estructura que requiere el panel. Por consistencia con las demás fuentes, se guarda además una versión **long** con `melt`: identificadores `departamento` y `anio`, y columnas `indicador` y `valor`. La cartera detallada se mantiene como base independiente; al panel (P06) solo se incorpora el agregado anual.

1.4 Carga y Resultados (Load)

Las bases se guardaron en formato Parquet en la ruta relativa `output/` del módulo (definida con `pathlib` a partir de la ubicación del script):

- `inversion_detalle.parquet`: cartera detallada, 2 230 proyectos (CUI único).
- `inversion_agregado.parquet`: agregado anual en formato ancho (6 filas).
- `inversion_agregado_long.parquet`: agregado en formato long (18 filas).

Año	Proyectos activos	Costo total (S/ mill.)	Avance ponderado (%)
2016	344	4 718.5	69.5
2017	403	6 518.1	63.4
2018	651	9 152.1	61.1
2019	987	15 791.4	54.3
2020	1 382	19 939.6	58.2
2021	1 793	26 737.9	57.5

De los 2 230 proyectos, 1 596 corresponden a gobiernos locales, 519 al gobierno nacional y 115 al gobierno regional. Por función, Transporte concentra el mayor costo (S/ 11 288 millones), seguido de Saneamiento (S/ 4 982 millones) y Educación (S/ 4 414 millones). El avance de 1 040 proyectos proviene del registro físico y el de 1 190 del financiero.

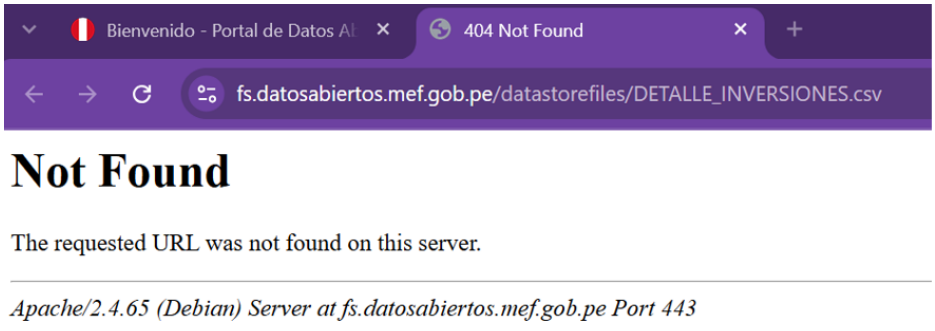
1.5 Resolución de problemas técnicos y limitaciones

- **API sin registros.** `datastore_search` respondía con éxito pero sin datos; se optó por la descarga directa del CSV.
- **Servidor de archivos fuera de servicio.** El 15/10/2026 el servidor `fs.datosabiertos.mef.gob.pe` devolvía *404 Not Found* para todos sus archivos, incluido el diccionario, aunque la página seguía mostrando el enlace. Se incorporaron reintentos y un mensaje de error explícito; el servicio se restableció el 16/10/2026 y el proceso se ejecutó sin modificar el código.
- **Archivo pesado.** Los 247 MB nacionales se procesan por bloques y solo con las columnas necesarias, para no saturar la memoria.
- **Solo inversiones activas.** Todos los registros del archivo tienen `ESTADO = ACTIVO`; las inversiones cerradas se publican en otro conjunto (*Cierre de inversiones*). Por ello la cartera de los primeros años está **subestimada**: faltan los proyectos que se ejecutaron entonces y ya se cerraron. Esto explica en parte el crecimiento de 344 a 1 793 proyectos.
- **Avance a la fecha de corte.** El avance corresponde a la última actualización del archivo (octubre de 2026), no al cierre de cada año. El avance ponderado anual mide, por tanto, cuánto se ha ejecutado *hoy* de la cartera que estaba activa en cada año.

Anexo obligatorio: Registro de consultas (prompts a IA)

Se detalla la bitácora de interacción utilizada durante el desarrollo del módulo 5:

[1] ¿Por qué me genera este error?



[2] ¿Qué es CKAN?

[3] Voy a seleccionar Detalle de inversiones, pero ¿puedo escoger otros datasets que encajan con cartera de inversiones, como el de Estado situacional de inversiones?

[4] ¿Es debido al navegador que se genera ese error 404?

[5] Con esa previsualización de etiquetas, crea una lista de columnas.

[6] Ayúdame a mejorar este código para descargar el CSV completo.

[7] Explícame estas librerías: `logging` y `unicodedata`.

[8] ¿Para qué sirve uncode y decode?

[9] No funciona el código que hice. ¿Crees que se deba al error 404 de la página donde se obtienen los datos? ¿Cuánto tiempo tengo que esperar?

[10] En la parte de Transform, ¿me dice que pase de long a ancho en la evaluación?

[11] El que me diste.

[12] El que me diste.

[13] Explícame qué es un archivo Parquet.

[14] ¿Cómo generar como resultado un archivo Parquet?

[15] Dime cómo podría crear un informe técnico. ¿Sería explicando cada archivo .py de extract, transform y load?